DIPLOMA AI ENGINEER · DMC INSTITUTE · PROYECTO INTEGRADOR

NormIA: asistente de documentación y cumplimiento para sistemas de gestión certificados

Sistema conversacional con recuperación aumentada (RAG), agente de herramientas con efecto real sobre la base de datos, fine-tuning con QLoRA y generación multimodal, sobre el sistema de gestión de la calidad de una empresa de logística. Ejecutado íntegramente en infraestructura propia: ningún documento sale de la máquina.

AUTOR

Klauz A. España Irrazabal

CLIENTE / CASO

ABISERVI, logística (Perú)

BLOQUES DEL DIPLOMA

Chatbot LLM + RAG · Agentes · Generativa texto e imagen

FECHA DE ENTREGA

22 de octubre de 2026

REPOSITORIO

github.com/klauzirrazabal-max/normia-chatbot-iso

VIDEO DEMOSTRATIVO

[enlace pendiente de grabación]

132	1 043	12 / 12	436
documentos controlados vigentes, en 12 áreas	cláusulas indexadas con código, versión y sección	consultas del banco acertadas con RAG (1 / 12 sin él)	tests automatizados, 19 ficheros, todos en verde

Este informe describe el problema, la metodología, la arquitectura, los resultados medidos y las limitaciones del prototipo. Todas las cifras provienen de ficheros del repositorio o de mediciones reproducibles indicadas en cada caso.

CONTENIDO

1. Resumen ejecutivo
2. El problema de negocio
3. Objetivos y criterios de verificación
4. Metodología de trabajo
5. Arquitectura de la solución
6. Recuperación aumentada sobre documentos controlados
7. Guardrails: controles deterministas
8. El agente y sus herramientas
9. Fine-tuning con QLoRA
10. Generación de material visual
11. Seguridad, roles y aislamiento
12. Resultados
13. El sistema en funcionamiento
14. Limitaciones
15. Conclusiones y próximos pasos
16. Instrucciones de instalación y uso

---

1. Resumen ejecutivo

En una organización certificada bajo ISO 9001, consultar un procedimiento exige saber tres cosas antes de leer nada: en qué documento está la respuesta, cuál es su versión vigente y en qué cláusula. Hoy eso se resuelve preguntándole a una persona del área de Calidad; cuando esa persona no está, se resuelve adivinando. Actuar sobre una versión derogada no es un despiste: es una no conformidad en auditoría.

NormIA es un asistente conversacional que responde preguntas sobre la documentación vigente **citando siempre código, versión y sección**, y que **no inventa**: cuando no tiene respaldo documental, lo dice y ofrece derivar la consulta al Responsable de Calidad. Además registra no conformidades y sus acciones correctivas (ciclo CAPA), detecta inconsistencias al ingerir documentos y produce material de concienciación con la cláusula que lo respalda.

La tesis del proyecto no es «un chatbot que responde» sino **trazabilidad auditable**. Por eso el diseño combina un modelo de lenguaje con una capa de controles deterministas que pueden descartar una respuesta ya redactada. Medido sobre un banco de 12 consultas reales, el modelo por sí solo acierta 1; con recuperación aumentada acierta 12 de 12 y no cita ningún documento inexistente.

Todo corre en una sola máquina, sin servicios externos: el modelo de lenguaje, los embeddings y la generación de imágenes son locales. No es una optimización sino la condición de partida, porque un sistema de gestión contiene procedimientos internos y organigramas que no pueden viajar a una API de terceros.

---

2. El problema de negocio

ABISERVI es una empresa peruana de logística con un sistema de gestión de la calidad (SGC) certificado. Su documentación controlada comprende **132 documentos vigentes en 12 áreas** (manuales, políticas, procedimientos, instructivos, formatos, planes, organigramas y listas maestras) que suman **1 043 cláusulas numeradas**. La unidad de respuesta casi nunca es «el documento»: es una cláusula concreta dentro de él.

Tres síntomas observados

- **El conocimiento está en una persona.** Las dudas operativas («¿cuánto tiempo tengo para atender un requerimiento?», «¿qué anillo del arnés vale para detener caídas?») se resuelven preguntando a Calidad. Cuando no está disponible, el operario actúa de memoria.
- **La versión importa tanto como el contenido.** Al ingerir el SGC real y cruzarlo contra su Lista Maestra aparecieron discrepancias: `CAL-IN-01` figura como v1 en la lista pero imprime v2 en su membrete; varios formatos referenciados por procedimientos vigentes no están registrados.
- **Las no conformidades se pierden entre el aviso y el registro.** Un hallazgo reportado de palabra no genera acción correctiva, y el ciclo CAPA que exige la cláusula 10.2 queda a medias.

Por qué inteligencia artificial, y por qué con límites

Un buscador clásico devuelve documentos; lo que la persona necesita es una respuesta en lenguaje natural con su referencia exacta. Un modelo de lenguaje resuelve la redacción, pero introduce el riesgo opuesto: responder con seguridad algo que no está en ningún documento. El problema de negocio, por tanto, no es «responder» sino **responder solo cuando hay respaldo y demostrar cuál es**. Eso define la arquitectura: el modelo redacta, pero no decide si la respuesta sale.

---

3. Objetivos y criterios de verificación

OBJETIVO	CÓMO SE VERIFICA
Responder sobre documentación vigente, citando siempre la fuente	Banco de 12 consultas reales (`scripts/benchmark_models.py`) con la respuesta correcta verificada leyendo el documento. Un documento marcado obsoleto deja de citarse en el mismo instante.
No inventar nunca un documento ni una acción	Cada código citado se comprueba contra la base; cada versión citada se corrige contra la real; cada ID de hallazgo o acción correctiva afirmado debe existir. Si no, la respuesta se descarta.
Cerrar el ciclo de no conformidad	Un hallazgo registrado exige responsable y fecha (`NOT NULL` en base) y queda visible en el panel de Calidad con los días que faltan.
Producir el material de concienciación que la norma exige	Cláusulas 7.2, 7.3 y 7.4 de ISO 9001 (competencia, toma de conciencia, comunicación). Cada pieza cita la cláusula que la respalda y la cita se valida contra el catálogo.
Que ningún documento salga de la organización	Modelos locales (LLM, embeddings, difusión). Restricción de partida, no optimización.

Los criterios son **medibles y automatizados**: 436 tests cubren guardrails, herramientas, enrutado, ingesta, consentimiento, autenticación y seguridad. Un objetivo que no se puede verificar no está en la lista.

4. Metodología de trabajo

El proyecto se desarrolló entre el **27 de agosto y el 22 de octubre de 2026** en 70 commits, con el SGC real del cliente desde el primer día (recomendación explícita de la guía: elegir un problema cuyos datos estén disponibles desde el inicio). Se siguieron cuatro principios:

1. **Medir antes de cambiar.** Cada decisión de modelo, umbral o prompt tiene una medición previa y otra posterior. La línea base del modelo de producción se congeló el 24/09/2026 (`docs/linea-base.md`) antes de entrenar ningún adaptador: un fine-tuning sin línea base no se puede defender.
2. **Los guardrails nacen de fallos observados, no de hipótesis.** Cada control tiene documentado el incidente que lo motivó, en el propio código, con el dato medido.
3. **Verificar el hecho, no la redacción.** No se buscan frases en la salida del modelo («he registrado…»): se comprueba contra la base si el registro existe. Cazar formulaciones se pierde siempre; un ID o está en la tabla o no está.
4. **Ensayo en vivo como prueba de aceptación.** El flujo completo (entrada, consulta, intento de engaño, subida de un PDF, ciclo CAPA, derogación de un documento, cambio de rol) se ejecutó en el navegador antes de dar por cerrada cada fase. Varios defectos descritos en la sección 14 se encontraron así y no en los tests.

Fases

FASE	TRABAJO	EVIDENCIA
1. Ingesta y RAG	Extracción de PDF con tablas, troceado por cláusula, embeddings locales, búsqueda vectorial con umbral, cruce contra la Lista Maestra.	`app/core/rag/` , `app/core/docs/`
2. Orquestador y guardrails	Enrutado de turnos, function calling, cuatro controles bloqueantes, traza de auditoría por turno.	`app/core/orchestrator.py` , `app/core/guardrails/`
3. Agente y CAPA	Nueve herramientas, registro de hallazgos y acciones correctivas, escalación con consentimiento.	`app/core/agents/tools.py`
4. Fine-tuning	Dataset de 584 ejemplos verificados, QLoRA en 4 bits, evaluación sobre casos excluidos del entrenamiento.	`data/finetune/` , `docs/comparacion-lora.md`
5. Generativa de imagen	SDXL con refinador, prompt juzgado por el LLM, composición del logotipo real, validación de la cláusula citada.	`app/channels/imagen_adapter.py`
6. Producto	Autenticación con tres roles, aislamiento por cliente, panel de Calidad, pantallas de inicio, asistente y material visual.	`app/channels/` , `frontend-widget/`

5. Arquitectura de la solución

Cuatro capas en una sola máquina. El cliente es un *Web Component* con Shadow DOM que se incrusta en cualquier intranet sin heredar ni imponer estilos; la API es FastAPI; el núcleo contiene el orquestador, la recuperación, las herramientas, los guardrails y el pipeline de ingesta; los modelos (Qwen3.8 27B vía Ollama y `BAAI/bge-m3`) corren en local; y PostgreSQL 16 con pgvector guarda documentos, cláusulas, conversaciones, hallazgos, acciones correctivas, escalaciones, usuarios y la traza de auditoría en un solo motor. El prototipo corre en una sola máquina; el mismo código se despliega en un servidor para n usuarios cambiando configuración, no código (sección 15).

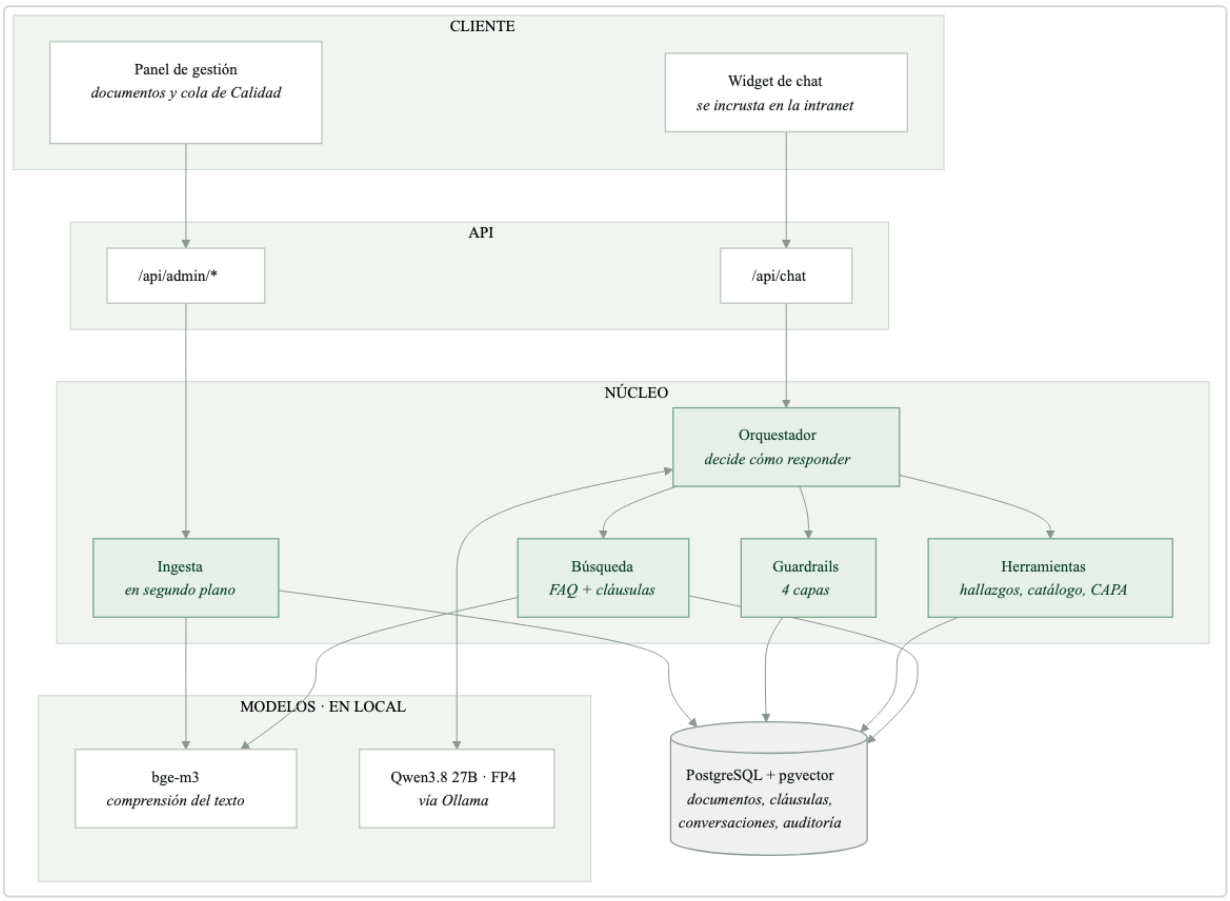


Figura 1. Vista general. Un solo motor de datos: integridad relacional (vigente/obsoleto) y búsqueda vectorial juntas, sin sincronizar dos sistemas.

CAPA	ELECCIÓN	POR QUÉ ESA
Backend	Python 3.12, FastAPI, SQLAlchemy	Estándar, fácil de probar. Endpoints síncronos despachados a hilos porque SQLAlchemy es síncrono.
Datos	PostgreSQL 16 + pgvector (HNSW) + unaccent	Relacional y vectorial en un motor; búsqueda insensible a acentos (los usuarios escriben «clausula»).

LLM	Qwen3.8 27B, FP4, Apache 2.0, vía Ollama	Licencia comercial limpia, sin coste por consulta. Elegido midiendo contra alternativas (`scripts/benchmark_models.py`). El cliente habla el protocolo compatible con OpenAI: vLLM o Groq entran cambiando tres variables.
Embeddings	`BAAI/bge-m3` , 1 024 dim, MIT	Multilingüe, local, sin clave de API.
Fine-tuning	QLoRA 4 bits sobre Qwen3-4B con MLX	Entrena el 0,37 % de los parámetros en una máquina de escritorio.
Imagen	SDXL base + refinador, Diffusers, MPS	El modelo dibuja la escena; el logotipo real se compone encima. Licencia OpenRAIL++-M, con restricciones de uso propagadas al usuario (`condiciones.html`).
Cliente	Web Component + Shadow DOM, sin framework	Incrustable en la intranet; sin fuentes web porque el producto corre sin internet.

Flujo de una consulta

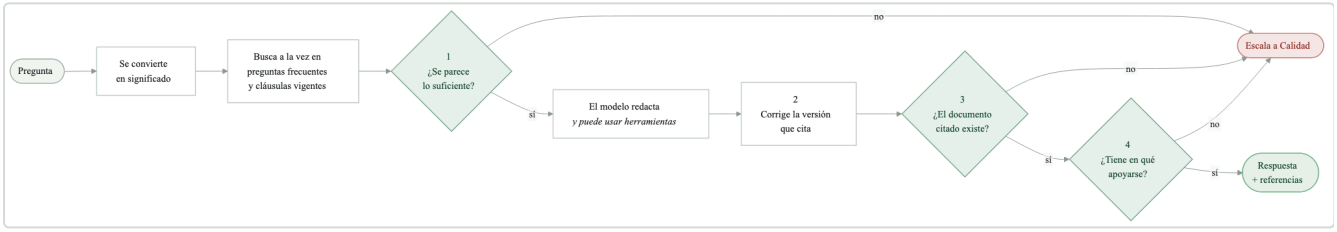


Figura 2. La pregunta se compara a la vez con las preguntas frecuentes verificadas y con las cláusulas vigentes. En rojo, los puntos donde la respuesta se descarta y la consulta se ofrece a Calidad.

Ingesta de documentos

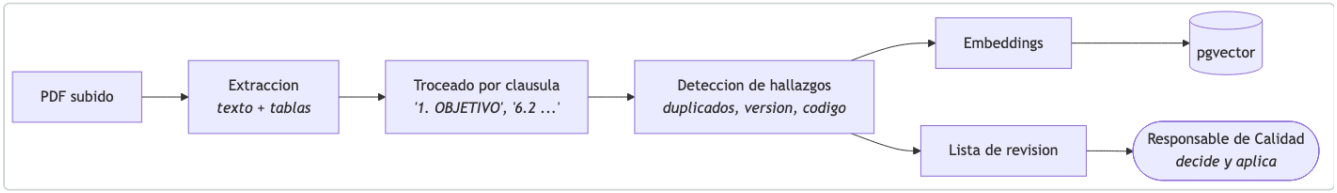


Figura 3. La identidad del documento se lee de su membrete (`CÓDIGO` , `VERSIÓN` , `REVISIÓN`), no del nombre del archivo, y se cruza contra la Lista Maestra. El sistema avisa; no modifica los documentos del cliente.

6. Recuperación aumentada sobre documentos controlados

Troceado por cláusula, no por tamaño. En un documento controlado la unidad de sentido es la cláusula («6.1.2», «7.4 Recepción y conformidad»). Trocear así es lo que permite citar «sección 7.2.4» con trazabilidad. Las tablas se extraen como texto estructurado (los tiempos de atención de TI viven en una tabla).

Dos búsquedas en paralelo. La pregunta se vectoriza una vez y se compara con el banco de **730 preguntas frecuentes verificadas** (generadas desde las cláusulas y comprobadas una a una contra su

texto) y con las cláusulas de documentos **vigentes**. Un documento marcado obsoleto desaparece del índice de búsqueda sin reindexar nada: es un filtro en la consulta.

Umbral absoluto y margen relativo. `ORDER BY distancia LIMIT k` siempre devuelve algo, por irrelevante que sea. El umbral (`RAG_MAX_DISTANCE = 0,527`, calibrado con `scripts/calibrate_threshold.py`) más un margen relativo del 8 % sobre el mejor resultado convierten la búsqueda en un guardrail: sin contexto suficiente, el modelo no redacta.

Carga directa de sección. Si el usuario pide «la sección 6.2 del COM-PR-01», no se pasa por el vector: se carga la cláusula exacta.

Traza de auditoría. Cada turno guarda qué se recuperó, a qué distancia, qué herramienta se llamó y si la respuesta quedó fundamentada (`messages.retrieval_debug`). Es lo que permite reconstruir, meses después, por qué el asistente dijo lo que dijo.

---

7. Guardrails: controles deterministas

Cinco controles pueden **descartar una respuesta ya redactada**. Todos son código, no instrucciones al modelo, y cada uno existe porque se observó el fallo que evita:

CONTROL	EL FALLO QUE LO MOTIVÓ	QUÉ HACE
1. Umbral semántico	Sin un mínimo de parecido, la búsqueda siempre devuelve algo.	Sin contexto, no se redacta: se ofrece derivar.
2. Versión citada	Escribió «STI-PO-01 v1» cuando el documento está en v2, contradiciendo su propia ficha de fuentes.	Corrige la versión contra la real y lo anota en la traza.
3. Código citado	Citó `PROC-CAL-04`, que no existe: lo copió del ejemplo de formato de su propio prompt.	Un código inexistente invalida la respuesta entera.
4. Fundamentación	Prometía derivar a Calidad sin que se registrara nada; se contaron 39 escalaciones sin registro.	La derivación existe en base o no se anuncia.
5. Registro afirmado	Respondió «la acción correctiva quedó registrada con el ID 100» sin haber ejecutado ninguna herramienta; la última acción era la 9.	Todo ID de hallazgo o acción afirmado se busca en la base. Si no está, se sustituye la respuesta.

> **Por qué deterministas.** El modelo local a veces escribe la llamada a herramienta como texto en vez de emitirla; el turno «funciona», no hay error, y la herramienta nunca se ejecuta. Un control que dependa de que el modelo se acuerde de algo desaparece en silencio justo cuando hace falta. Por eso el consentimiento para derivar, la verificación de citas y la de registros no son herramientas: son código que se ejecuta siempre.

Consentimiento antes de derivar. Nada entra en la bandeja de Calidad sin que el usuario diga que sí. Toda respuesta que deje una propuesta de derivación abierta termina con la misma pregunta, venga de

un guardrail o de una herramienta, y el turno siguiente se resuelve comprobando eso. Antes de este control la bandeja acumuló 306 consultas que nadie había pedido derivar; una bandeja así se deja de mirar.

Otros controles previenen antes de llegar ahí: filtro de alcance con suelo determinista y juicio del modelo para el material visual, detección de inyección de prompt en la escena, recuperación de llamadas a herramienta escritas como texto, cortacircuitos ante fallos del LLM, límite de peticiones por IP y tiempo máximo por consulta.

8. El agente y sus herramientas

No es un enrutador de intenciones: las nueve herramientas se exponen por *function calling* y **el modelo elige**. Cuatro de ellas tienen efecto real sobre la base de datos.

HERRAMIENTA	QUÉ HACE	EFECTO
`buscar_documentos`	«¿Tienen políticas de TI?»: consulta el catálogo por título, código y área.	lectura
`leer_documento`	Resume un documento completo y ofrece navegar sus secciones.	lectura
`register_finding`	Registra una no conformidad con severidad y área.	escribe
`ampliar_hallazgo`	Añade detalle a un hallazgo ya registrado.	escribe
`registrar_accion_correctiva`	Cierra el ciclo CAPA: exige acción, responsable y fecha; deduplica.	escribe
`get_capa_status`	Estado de las acciones correctivas de un hallazgo.	lectura
`escalate_to_quality`	Propone la derivación al responsable humano y la deja registrada, pendiente de confirmación.	escribe
`describir_capacidades`	Responde sobre sí mismo sin consultar el SGC.	—
`generar_material_visual`	Prepara un cartel con respaldo documental y lo entrega a la página de material visual.	—

El ciclo CAPA, en un hilo. El operario cuenta lo que vio; el agente lo clasifica (menor, mayor, observación), lo registra y **pregunta quién se encargará y para cuándo**. Con esos dos datos registra la acción correctiva y el hallazgo pasa a «en revisión». La fecha relativa («antes del 15 de noviembre») se interpreta con la fecha del día inyectada en el prompt: sin ella el modelo devolvía fechas del año anterior y la acción nacía vencida.

9. Fine-tuning con QLoRA

El objetivo del fine-tuning no era que el modelo «supiera» el SGC (eso lo resuelve la recuperación) sino que **respondiera en el formato del producto**: cita con código, versión y sección; llamada a herramienta como *tool call* y no como texto; negativa con escalación cuando no hay respaldo.

Dataset

584 ejemplos ensamblados **de lo que el proyecto ya tenía verificado**, no redactados a mano (`scripts/build_finetune_dataset.py`):

FAMILIA	EJEMPLOS	QUÉ ENSEÑA
`cita`	400	Responder con respaldo y citar código, versión y sección (de las 730 FAQ verificadas; recortada para no ahogar a las demás).
`herramienta`	135	Emitir la llamada como *tool call*, no escribirla en el texto.
`escalacion`	31	Negarse y llamar a `escalate_to_quality` sin respaldo.
`fantasma`	14	No citar un documento inexistente (los 14 rechazos documentados del FAQ).
`social`	4	Saludar sin escalar a Calidad.

Reparto 468 / 57 / 59 (train / valid / test) **por grupo de cláusula de origen**, no por ejemplo: dos preguntas de la misma cláusula comparten casi todo el prompt y separarlas convertiría la validación en una medida de memorización. Las 12 preguntas del banco de pruebas quedan **fuera de las tres particiones**.

Entrenamiento

QLoRA sobre `mlx-community/Qwen3-4B-4bit` con MLX en Apple Silicon: **0,365 % de parámetros entrenables** (14,7 M de 4 022 M), 400 iteraciones, tasa de aprendizaje 1e-4, memoria pico 11,3 GB. Pérdida de validación de 2,259 a 0,221; pérdida en test 0,284 (perplejidad 1,33). Registro completo en `docs/entrenamiento.log`.

Resultado

Sobre las 12 consultas excluidas del entrenamiento, el modelo base acierta **11 de 12** y el afinado **12 de 12** (`docs/comparacion-lora.md`, con las respuestas completas de ambos). Lo que cambia no es tanto el acierto como la forma: la respuesta pasa de una mediana de 1 014 a 160 caracteres y cita de forma más consistente. Es un resultado independiente y medido, como pide la guía, y se presenta separado del que aporta el RAG.

> **Un efecto secundario medido:** el fine-tuning empeoró la emisión de llamadas a herramienta del 100 % al 75 % en una de las mediciones. Entrenar una llamada como texto la empuja hacia su forma de texto. El control de «registro afirmado» de la sección 7 existe en parte por esto.

---

10. Generación de material visual

ISO 9001 pide formar y comunicar (cláusulas 7.2, 7.3 y 7.4). El material de concienciación no es decoración: da servicio a tres cláusulas del estándar. NormIA genera carteles y señalética **que citan la cláusula que los respalda**, y la cita se valida contra el catálogo: no se puede imprimir un respaldo que no existe.

- **La escena la escribe el usuario en castellano**; el modelo la traduce a un prompt telegráfico en inglés y **juzga si está dentro del alcance** de un sistema de gestión (un suelo determinista rechaza

lo inaceptable; el resto lo decide el modelo, incluida la detección de inyección de prompt en la propia escena).

- **SDXL base + refinador en MPS**, con el VAE de precisión corregida. El refinador trabaja sobre la imagen decodificada, no sobre latentes: el traspaso en latentes desbordaba en fp16 y devolvía imágenes negras.
- **El texto no lo dibuja el modelo.** El titular, el logotipo real y la cita de la cláusula se componen encima; el modelo solo dibuja la escena. Un modelo de difusión escribe letras ilegibles.
- **Los prompts caben en 77 tokens.** CLIP corta en 77 sin avisar; el negativo llegó a tener 135 y el modelo descartaba 58, entre ellos los términos contra deformidades. Un test lo mide con el tokenizador real.
- **Licencia.** SDXL es CreativeML OpenRAIL++-M: permite el uso como servicio pero obliga a propagar sus restricciones; `condiciones.html` las muestra al usuario. En producción se sustituiría por FLUX.1 (Apache 2.0).



Figura 4. Pieza generada en 44 s en local, con el logotipo real compuesto encima. Fondo liso y figura separada del fondo tras corregir el presupuesto de tokens del prompt.

11. Seguridad, roles y aislamiento

ASPECTO	IMPLEMENTACIÓN
Autenticación	`hashlib.scrypt` para contraseñas y cookie de sesión firmada con HMAC-SHA256 (`httpOnly`, 12 h). Sin dependencias externas.
Tres roles	**operario** (consulta, reporta, ve sus hallazgos), **calidad** (gestión documental, bandeja, CAPA), **admin**. Todo `/api/admin/*` exige rol de Calidad a nivel de router: cuatro intentos de un operario devuelven 403.
Aislamiento por cliente	El tenant se toma de la sesión, nunca del cuerpo de la petición. Con `PUBLIC_TENANT_ID`, el anónimo solo ve el corpus público.

Límite de peticiones	Ventana deslizante por IP. La cabecera de reenvío solo se lee con `TRUSTED_PROXY` declarado; medido: sin eso, 60 peticiones con la cabecera falseada y 0 bloqueadas.
Resiliencia	Cortacircuitos ante fallos del LLM, reintentos acotados, tiempo máximo de 60 s, incidentes con número de referencia visible al usuario.
Datos	Ningún documento ni consulta sale de la máquina. Sin fuentes web ni CDN en la interfaz.

---

12. Resultados

Tres mediciones distintas, con sus ficheros de origen. No deben mezclarse: responden a preguntas diferentes.

12.1 Qué aporta cada pieza (mismo modelo, tres estados)

Modelo `Qwen3-4B-4bit` sobre las 12 consultas del banco (`docs/tres-estados-empresa-demo-iso.md`):

MÉTRICA	SIN RAG	CON RAG	RAG + LORA
Acierta en conjunto	8 %	100 %	100 %
Cita el documento correcto	25 %	100 %	100 %
Usa la herramienta correcta	0 %	100 %	100 %
Escala cuando debe	75 %	100 %	100 %
Sin citas inventadas	92 %	100 %	100 %

La primera columna es la razón de ser del proyecto: un modelo sin los documentos delante responde con seguridad y se inventa el código del procedimiento (`STI-MA-02` , que no existe en el SGC).

12.2 Línea base del modelo de producción

`qwen3.8:27b-mlx` con RAG, congelada el 24/09/2026 antes de cualquier fine-tuning (`docs/linea-base.md`): cita el documento correcto 88 %, acierta la cláusula 100 %, sin citas inventadas 100 %, latencia mediana 14,8 s. Su punto débil medido era la herramienta correcta (50 %), que es lo que motivó el dataset de la familia `herramienta` .

12.3 Valor del fine-tuning (casos no vistos)

Base 11 / 12 frente a LoRA 12 / 12 sobre las consultas excluidas del entrenamiento, con latencia mediana 7,5 s frente a 7,9 s: la mejora no penaliza el tiempo de respuesta.

12.4 Rendimiento del sistema completo (ensayo del 22/10/2026)

2,7 s	**~15 s**	**44 s**	**17,5 GB**
consulta documental con el modelo caliente (5,9 s en frío)	turno del ciclo CAPA con llamada a herramienta	pieza visual con refinador, en local (70 s en frío)	memoria del LLM; SDXL 6,6 + refinador 5,8 GB, liberados al terminar

12.5 Verificación automatizada

436 tests en 19 ficheros, 3 s de ejecución. Los de mayor peso: enrutado (46), consentimiento (44 + 9), herramientas (36), citas (27), troceado (27), imágenes (26), autenticación (25), fundamentación (23), seguridad (18), CAPA (16). Varios tests nacieron de un defecto encontrado en vivo y escriben en su docstring el incidente que reproducen.

---

13. El sistema en funcionamiento

Capturas del ensayo completo del 22 de octubre de 2026 sobre el SGC real, con sesión del Responsable de Calidad.



Figura 5. Consulta sobre el arnés: la respuesta cita `OPE-PR-04 v1`, sección 7.2.4, con la fecha desde la que está vigente. Los chips de debajo navegan a otras secciones del mismo documento.



Figura 6. Se le pide citar un procedimiento inexistente. El modelo escribió el código; el control 3 lo detectó, descartó la respuesta y preguntó si derivar. Nada entra en la bandeja sin un sí.



Figura 7. El modelo afirmó haber registrado un hallazgo sin llamar a la herramienta. El control 5 lo sustituyó por un mensaje veraz en vez de dar por hecho un registro que no existe.

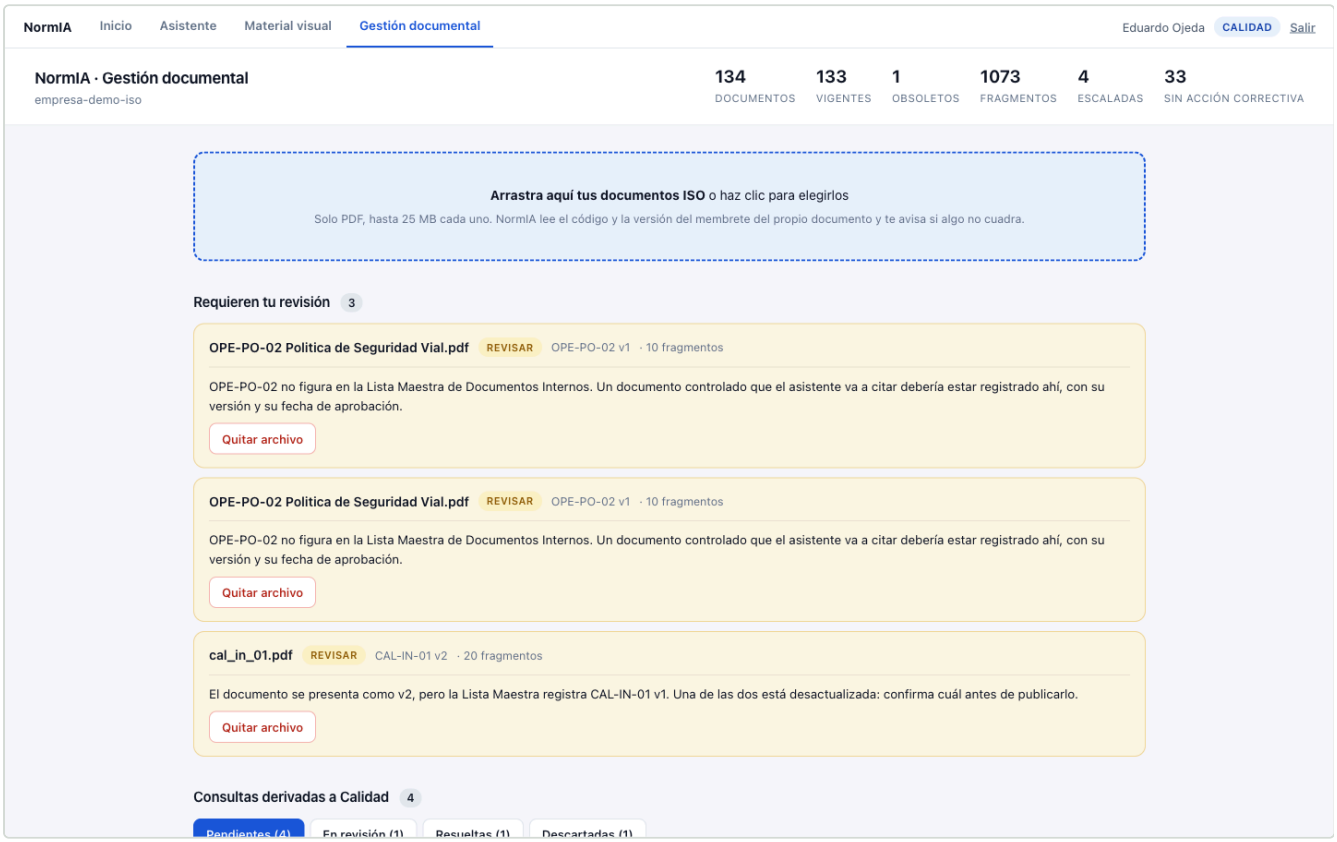


Figura 8. Se sube una política nueva arrastrando el PDF. El sistema lee código y versión del membrete y avisa de que `OPE-PO-02` no figura en la Lista Maestra. Debajo, la cola de consultas derivadas con su motivo.

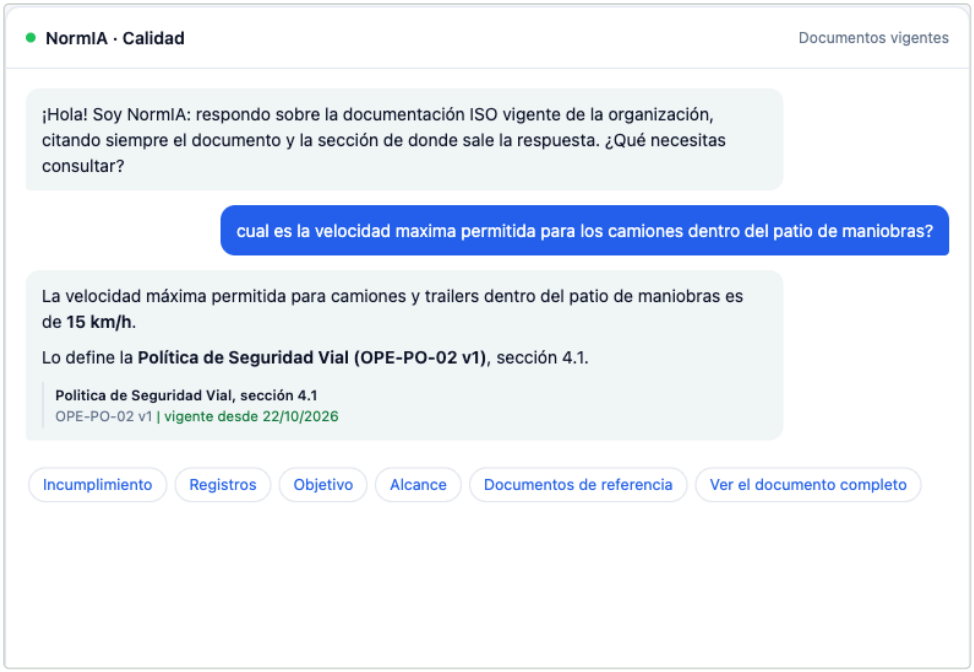


Figura 9. La pregunta que minutos antes no tenía respaldo («velocidad máxima en el patio de maniobras») ahora se responde citando la sección 4.1 del documento recién subido, vigente desde ese día.

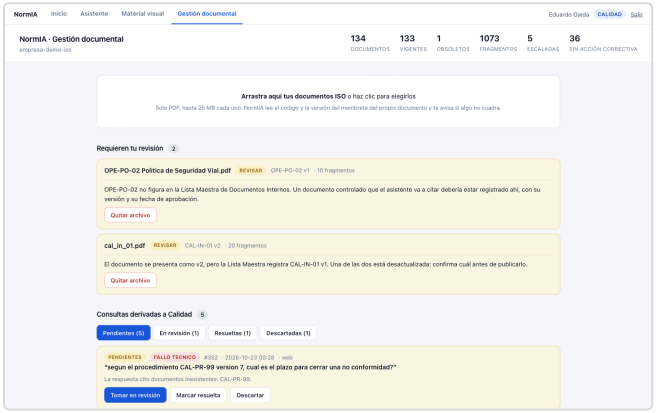


Figura 10. Panel de Calidad: documentos que requieren revisión, consultas derivadas con su motivo y, más abajo, las no conformidades con su acción correctiva y los días que faltan.

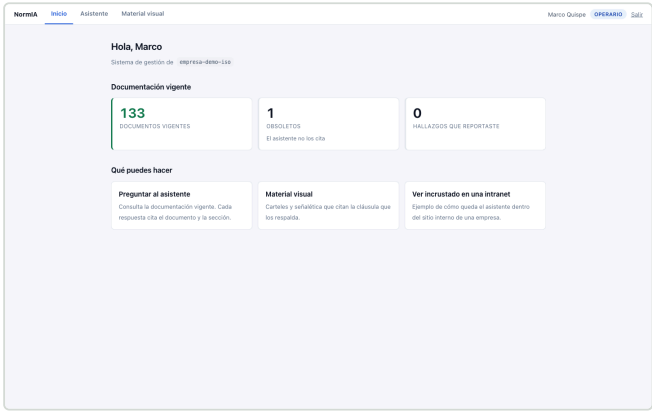


Figura 11. La misma aplicación con sesión de operario: desaparece la gestión documental y las métricas se reducen a lo que le concierne. Las llamadas directas a `/api/admin/*` devuelven 403.

14. Limitaciones

Se enumeran las que un tribunal preguntaría primero, incluidas las encontradas en el ensayo final. Ninguna está maquillada.

1. **El banco son 12 consultas.** Suficiente para ver un patrón, corto para afirmar un porcentaje con intervalo de confianza.
2. **Contenido inventado con cita real.** Preguntado por cotizaciones de compras, el sistema respondió «tres cotizaciones para compras mayores a 1 000 soles» citando `COM-PR-01 v3, sección 6.1.2`. El documento existe, la sección existe, pero dice «una cotización» y no hay umbral alguno: la búsqueda trajo una plantilla en blanco titulada «Cotización» y el modelo rellenó el hueco con conocimiento general. El sistema **lo detecta** (evento `citation_not_retrieved`: el código citado

no estaba entre lo recuperado) pero hoy solo lo registra. Conectarlo como bloqueo es el siguiente cambio, y el más importante.

3. **La llamada a herramienta no es fiable turno a turno.** El modelo local a veces escribe en prosa que registró algo sin emitir la llamada. El control de registro afirmado lo convierte en un mensaje veraz y recuperable, pero no lo evita. Ollama ignora `tool_choice`, así que no se puede forzar.
4. **El fine-tuning empeoró la emisión de llamadas** del 100 % al 75 % en una medición.
5. **24 cláusulas del SGC son imágenes** y una está escaneada: hoy se descartan en la ingesta. Harían falta OCR y un modelo de visión.
6. **Deduplicación de hallazgos por huella**: dejó pasar dos registros casi idénticos del mismo extintor con redacción distinta.
7. **Al borrar un documento, su trabajo de subida queda huérfano** en la lista de revisión.
8. **El material visual no entra en documentos controlados.** Formación sí; documento del SGC no: sería un problema de auditoría.
9. **Sin pruebas de carga.** Generar una imagen bloquea un hilo 44 s; el límite de peticiones y el cortacircuitos viven en memoria del proceso.

---

15. Conclusiones y próximos pasos

Lo que el proyecto demuestra. Un modelo de lenguaje local, sin los documentos delante, acierta 1 de 12 consultas sobre un SGC real e inventa códigos de procedimiento. Con recuperación por cláusula, umbral semántico y una capa de controles deterministas, acierta 12 de 12 y no cita nada que no exista. El fine-tuning, medido por separado sobre casos no vistos, mejora el formato sin penalizar la latencia. El agente cierra el ciclo de no conformidad con registros reales, verificables en la base, y nada se deriva a Calidad sin consentimiento.

Lo que aprendimos. Los fallos más caros no fueron de precisión sino de *promesa incumplida*: el sistema afirmando que había derivado, registrado o generado algo que no existía. Todos se resolvieron del mismo modo, verificando el hecho contra la base en vez de confiar en la redacción. Y los defectos más importantes se encontraron ensayando el flujo completo en el navegador, no en los tests: la cobertura automatizada no sustituye el uso real.

Despliegue en servidor para n usuarios

El objetivo de producto es un servidor al que consulten decenas o cientos de personas, no un portátil. Lo que hace eso viable ya está resuelto: PostgreSQL con pgvector escala sin tocarlo, la sesión es una cookie firmada sin estado en el servidor, el cliente del LLM habla el protocolo de OpenAI (vLLM entra con tres variables) y los guardrails son código determinista que corre igual en cada worker.

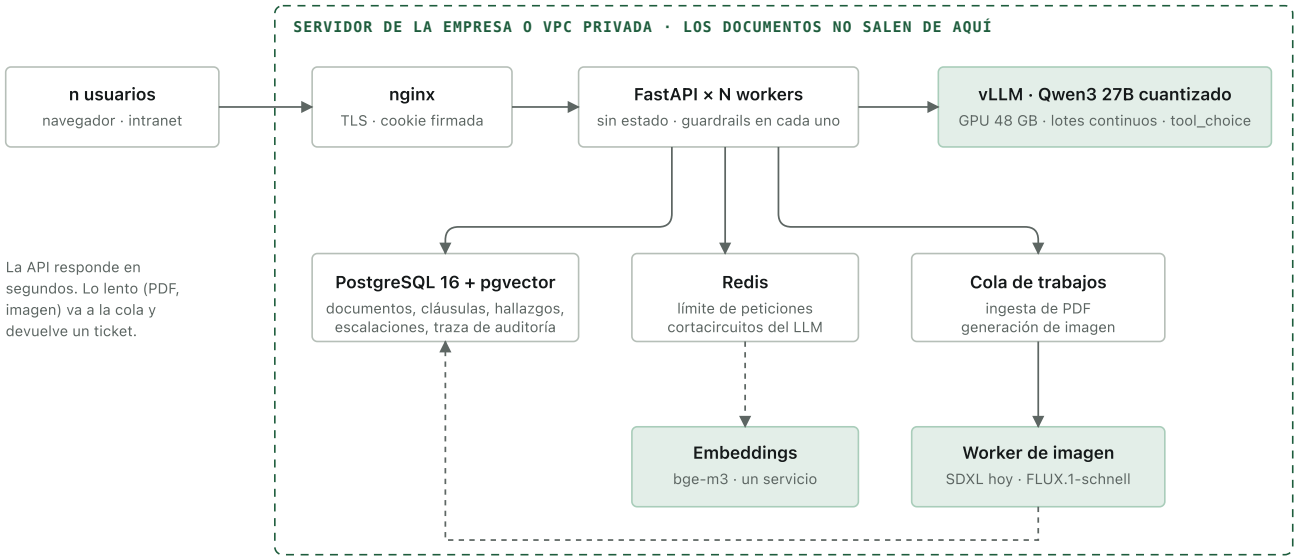


Figura 12. Despliegue propuesto. Los recuadros verdes son los que necesitan GPU. Todo queda dentro del servidor de la empresa o de una nube privada bajo su control: *local* significa bajo control de la organización, no en un portátil.

Lo que hoy vive en memoria del proceso y hay que sacar fuera para tener varios workers:

PIEZA	HOY	PARA N USUARIOS
Límite de peticiones	Ventana deslizante en RAM del proceso	Redis: con cuatro workers, cada uno llevaría su propia cuenta.
Cortacircuitos del LLM	En el cliente, por proceso	Redis, por la misma razón.
Ingesta de PDF	`BackgroundTasks` dentro de la API	Cola de trabajos: un PDF grande no debe ocupar un worker web.
Generación de imagen	Síncrona, 44 s bloqueando un hilo	Worker aparte o serverless; la API devuelve un ticket.
Servidor del modelo	Ollama: atiende en serie e ignora `tool_choice`	vLLM en Linux con GPU: lotes continuos y llamadas a herramienta forzadas. No corre en Apple Silicon.

Nada de esto es un rediseño: es mover estado fuera del proceso. El orquestador, las herramientas y los controles no cambian.

Capacidad y coste

Qwen3 27B cuantizado a 4 bits ocupa unos 16 GB de GPU; la concurrencia típica de 100 usuarios reales es de 5 a 10 consultas simultáneas, así que una GPU basta.

OPCIÓN DE SERVIDOR	COSTE APROXIMADO	CAPACIDAD ESPERADA	DÓNDE VIVEN LOS DATOS
Servidor propio con una GPU de 48 GB (L40S)	8–15 k$, una vez	10–20 consultas simultáneas	en la empresa
Nube privada del cliente, instancia con GPU de 48 GB	1 200–1 800 $/mes	10–20 simultáneas	VPC del cliente

Modelo menor (Qwen3 8B) en GPU de 24 GB (L4)	~500 $/mes	similar; habría que repetir el banco	VPC del cliente

> **Lo que no está medido.** Las capacidades de esta tabla son el orden esperable para esa GPU con vLLM, no una medición de este proyecto: no se ha servido este modelo con vLLM ni se han hecho pruebas de carga (limitación 9). Presentar ese número como medido sería justo lo que el proyecto critica. El coste de la generación de imagen es despreciable frente al del LLM: el material visual es de volumen mínimo y puede pagarse por segundo de GPU.

Próximos pasos, por orden

PASO	POR QUÉ
Bloquear la cita no recuperada	El detector existe y registra el evento; falta tratarlo como bloqueo, igual que la cita inexistente. Es la limitación 2.
Servir con vLLM en vez de Ollama	Medido: Ollama ignora `tool_choice` y atiende en serie. Implica un servidor Linux con GPU: vLLM no corre en Mac.
Cola para lo lento	Generar una imagen bloquea un hilo 44 s; la ingesta de PDF, igual.
Estado compartido en Redis	Cortacircuitos y límite de peticiones por proceso: con dos instancias, cada una lleva su cuenta.
OCR y visión para lo escaneado	Recupera las 24 cláusulas que hoy se pierden.
Norma agnóstica	Campo de norma por cliente para que ninguna pantalla fije «ISO 9001»: el mismo producto sirve a 14001, 45001 o 27001.

Lo que **no** cambiaría: el modelo en local. Para un sistema de gestión certificado eso no es una ventaja técnica; es la condición para que el proyecto exista.

---

16. Instrucciones de instalación y uso

Requisitos: macOS o Linux, Docker, Python 3.12 (`uv` lo instala), Ollama con el modelo indicado y unos 24 GB de memoria para el LLM. La generación de imágenes necesita 13 GB adicionales durante la pieza.

```
git clone https://github.com/klauzirrazabal-max/normia-chatbot-iso.git
cd normia-chatbot-iso
cp .env.example .env                        # revisa LLM_MODEL, DATABASE_URL, ADMIN_API_KEY
docker compose -f docker/docker-compose.yml up -d     # PostgreSQL 16 + pgvector
uv sync                                     # Python 3.12 y dependencias con lockfile
ollama pull qwen3.8:27b-mlx

uv run python scripts/seed_demo_tenant.py --tenant demo-publica --name "Empresa Demo"
uv run python scripts/ingest_docs.py --tenant demo-publica     # troceado por cláusula +
embeddings
uv run python scripts/load_registry.py --tenant demo-publica   # Lista Maestra
uv run python scripts/crear_usuario.py calidad@empresa.com --rol calidad

uv run uvicorn app.main:app --port 8000
# http://localhost:8000  →  acceso, inicio, asistente, material visual, gestión documental

uv run pytest -q                            # 436 tests
```

El repositorio incluye un SGC sintético (`scripts/generate_demo_corpus.py`) para que el proyecto se pueda clonar y ejecutar: los documentos reales de un cliente son información controlada y no entran en git. El `README.md` (913 líneas) documenta cada decisión, el umbral de distancia, la comparación de modelos y la verificación.

VARIABLE	PARA QUÉ
`LLM_BASE_URL, LLM_MODEL`	Cualquier servidor compatible con OpenAI: Ollama, vLLM, Groq.
`RAG_MAX_DISTANCE, RAG_RELATIVE_MARGIN`	Umbral absoluto y margen relativo del guardrail semántico.
`PUBLIC_TENANT_ID`	Fija el corpus que ve un visitante anónimo; ignora lo que mande el cliente.
`TRUSTED_PROXY`	Detrás de qué proxy se está, para leer la IP real sin que el cliente la falsee.