PROYECTO INTEGRADOR, DIPLOMA AI ENGINEER, DMC INSTITUTE

NormIA: asistente de documentación y cumplimiento ISO 9001

Sistema conversacional con recuperación aumentada, agente de herramientas y generación multimodal, sobre el sistema de gestión de la calidad de una empresa de logística. Ejecutado íntegramente en infraestructura propia.

AUTOR	CLIENTE	BLOQUES	ENTREGA
Klauz A. España Irrazabal	ABISERVI, logística	Chatbot, agentes, generativa	22 de octubre de 2026

EL CASO DE NEGOCIO

Consultar un procedimiento exige conocer documento, versión y cláusula

Para responder «¿cuánto tiempo tengo para atender un requerimiento?» hay que saber tres cosas antes de leer nada: en qué documento está, cuál es la versión vigente y en qué sección.

132

documentos controlados

En 11 áreas: manuales, políticas, procedimientos, instructivos y formatos.

1043

cláusulas numeradas

La respuesta casi nunca es «el documento». Es una cláusula concreta dentro de él.

v1 ≠ v2

el riesgo real

Actuar sobre una versión derogada es una no conformidad en auditoría, no un despiste.

Hoy eso se resuelve preguntando a Calidad. Cuando esa persona no está, se resuelve adivinando, y un asistente que también adivine **empeora el problema**.

ALCANCE Y VERIFICACIÓN

Cuatro objetivos, cada uno con su criterio de verificación

133
documentos vigentes
En 12 áreas del SGC real.

1043
cláusulas indexadas
Código, versión y sección.

12/12
consultas acertadas
Con RAG. Sin él, 1 de 12.

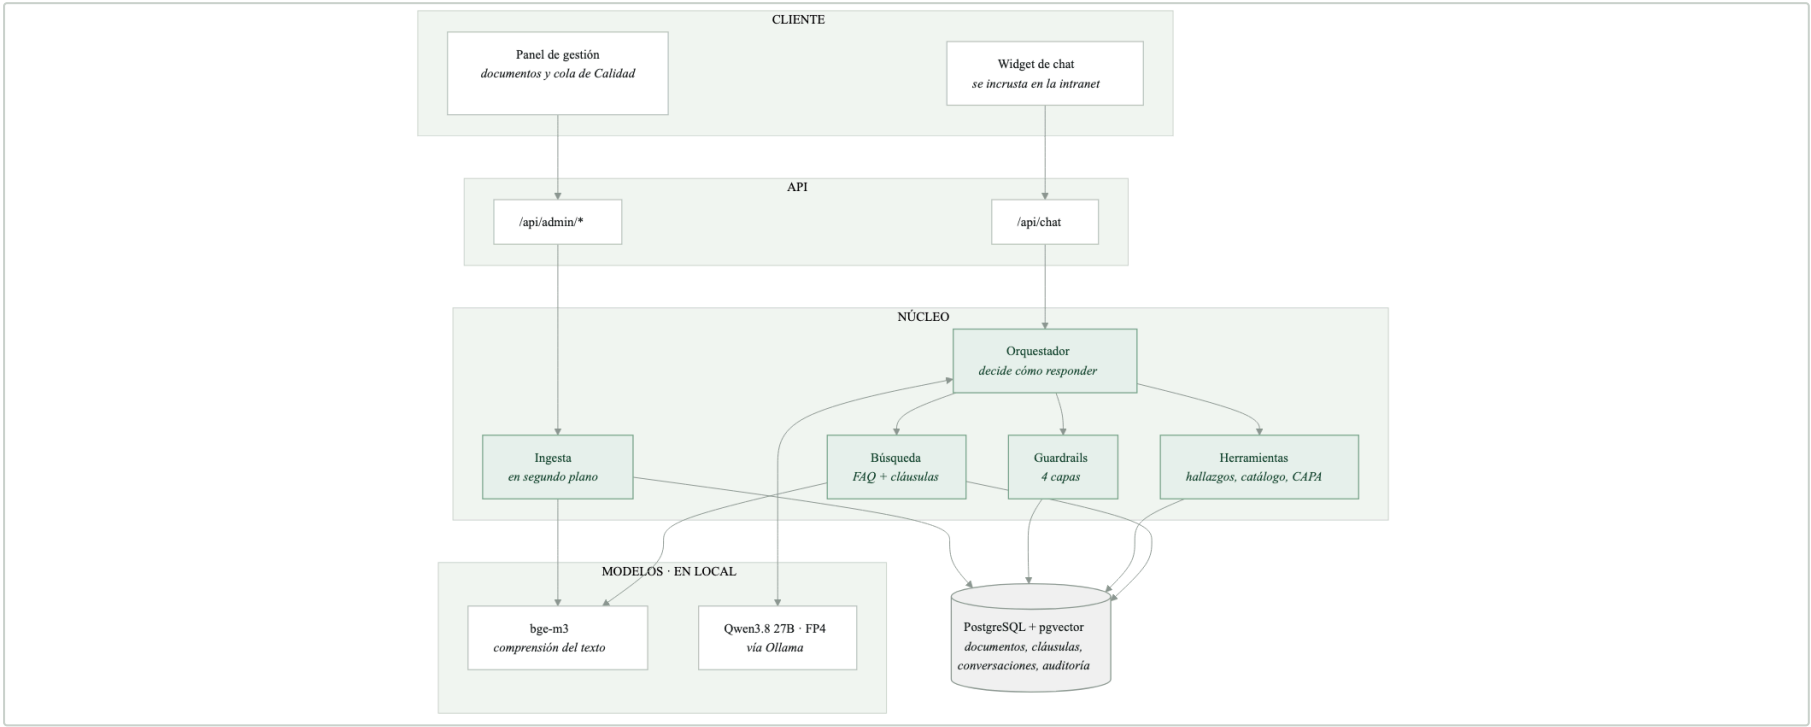
436
tests en verde
Guardrails, agente, ingesta.

OBJETIVO	CÓMO SE VERIFICA
Responder sobre documentación vigente, citando siempre la fuente	Banco de 12 consultas reales con la respuesta verificada leyendo el documento
No inventar nunca un documento	Cada código citado se comprueba contra la base. Si no existe, la respuesta se descarta
Producir el material de concienciación que la norma exige	las cláusulas 7.2, 7.3 y 7.4 de ISO 9001: competencia, toma de conciencia y comunicación
Que ningún documento salga de la organización	Modelos locales. Es una **restricción de partida**, no una optimización

El último condiciona todo lo demás: un SGC contiene procedimientos internos y organigramas, y eso no puede viajar a una API de terceros.

VISTA GENERAL

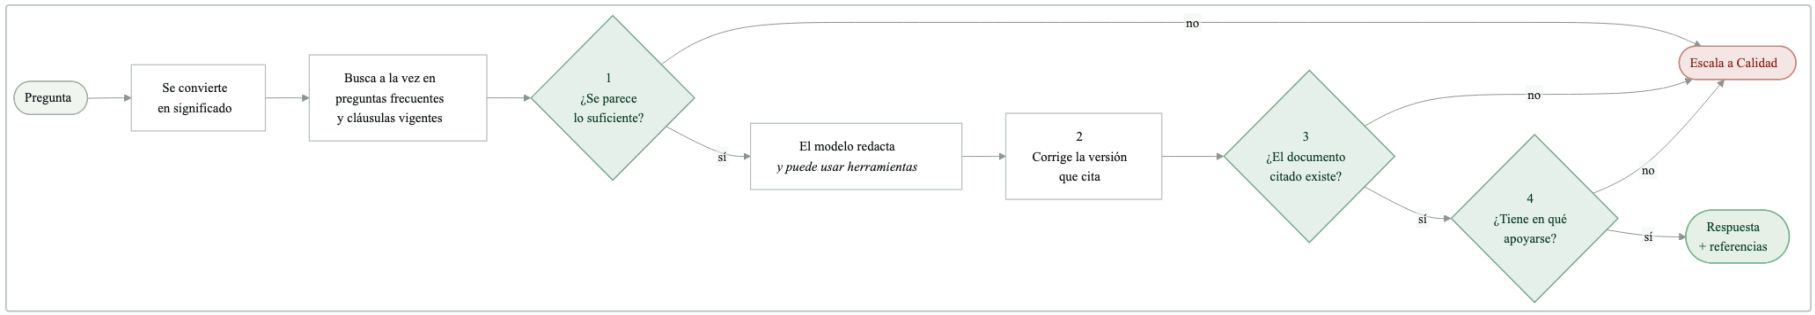
Arquitectura en cuatro capas, ejecutada en una sola máquina



Nada sale de la máquina. El modelo de lenguaje corre en local y los embeddings también; PostgreSQL guarda documentos, cláusulas, conversaciones, hallazgos y la traza de auditoría.

PASO A PASO

Cuatro controles pueden descartar una respuesta ya redactada



La pregunta se compara **a la vez** con las preguntas frecuentes y con las cláusulas vigentes. Desde ahí, cuatro guardrails: en cualquiera de ellos la respuesta se descarta y la consulta pasa a la cola de Calidad.

STACK Y LICENCIAS

Seis decisiones técnicas, con la licencia verificada en cada una

CAPA	ELECCIÓN	POR QUÉ ESA
Backend	Python 3.12 y FastAPI	Estándar, fácil de probar. **436 tests** cubren guardrails y herramientas.
Base de datos	PostgreSQL 16 con pgvector	Integridad relacional (vigente/obsoleto) **y** búsqueda vectorial en un solo motor. Con dos, habría que sincronizarlos.
LLM	Qwen3, Apache 2.0, en local	Licencia comercial limpia y sin coste por consulta. Elegido **midiendo**, no por ser el más nuevo.
Embeddings	BAAI/bge-m3, licencia MIT	1024 dimensiones, corre en local sin clave de API.
Fine-tuning	QLoRA en 4 bits	Base congelada; se entrena el **0,37 %** de los parámetros.
Imagen	SDXL con Diffusers	El modelo dibuja la escena; el logotipo real se **compone encima**. Licencia **OpenRAIL++**, la única con restricciones de uso: en producción se sustituiría por FLUX.1, que es Apache 2.0.

BLOQUE DE AGENTES INTELIGENTES

El agente expone nueve herramientas y el modelo selecciona

HERRAMIENTA	QUÉ HACE
`buscar_documentos`	«¿Tienen políticas de TI?», consulta el catálogo
`leer_documento`	Resume un documento y ofrece navegar sus secciones
`register_finding y ampliar_hallazgo`	**Escriben en la base:** registran una no conformidad
`registrar_accion_correctiva`	**Cierra el ciclo CAPA:** exige acción, responsable y fecha
`get_capa_status`	Estado de las acciones correctivas de un hallazgo
`escalate_to_quality`	Deriva al responsable humano y **lo registra**
`describir_capacidades`	Responde sobre sí mismo sin consultar el SGC
`generar_material_visual`	Prepara un cartel con respaldo documental

No es un enrutador de intenciones: las herramientas se exponen por *function calling* y **el modelo elige**. Cuatro de ellas tienen efecto real sobre la base de datos.

GUARDRAILS

Cinco controles derivados de fallos observados en producción

CONTROL	EL FALLO QUE LO MOTIVÓ
1. Umbral semántico	Sin un mínimo de parecido, la búsqueda **siempre** devuelve algo, aunque no tenga nada que ver.
2. Versión citada	Escribió «STI-PO-01 v1» cuando el documento está en v2, contradiciendo su propia ficha de fuentes.
3. Código citado	Citó `PROC-CAL-04`, que no existe: lo copió del **ejemplo de formato** de su propio prompt.
4. Fundamentación	Prometía derivar a Calidad sin que se registrara nada. Prometer y no cumplir es peor que declararse incapaz.
5. Registro afirmado	«La acción correctiva quedó registrada con el ID 100», sin haber ejecutado ninguna herramienta. La última era la 9. **Todo ID afirmado se busca en la base.**

Los cinco pueden **descartar una respuesta ya redactada**. Otros ocho controles evitan llegar ahí. Todos son **código determinista**, no confianza en el modelo: por eso se pueden auditar.

FINE-TUNING CON QLORA

QLoRA eleva la cita correcta del 88 % al 100 % sin penalizar la latencia

584 ejemplos ensamblados de lo que el proyecto **ya tenía verificado**: 730 respuestas comprobadas contra el texto de su cláusula, los 14 rechazos documentados y los esquemas de las herramientas.

MÉTRICA	SIN AFINAR	CON FINE-TUNING
Cita el documento correcto	**88 %**	**100 %**
Marcada como fundamentada	**88 %**	**100 %**
Sin citas inventadas	**100 %**	**100 %**
Latencia mediana	**7,5 s**	**7,9 s**

Medido sobre el sistema completo, con la documentación recuperada delante, que es como funciona en producción.

En una segunda medición **sin recuperación**, para aislar qué aporta el modelo por sí mismo, la respuesta pasa de **1014 a 160 caracteres** y la atribución correcta sube del 38 % al 62 %. Son dos experimentos distintos y no deben mezclarse.

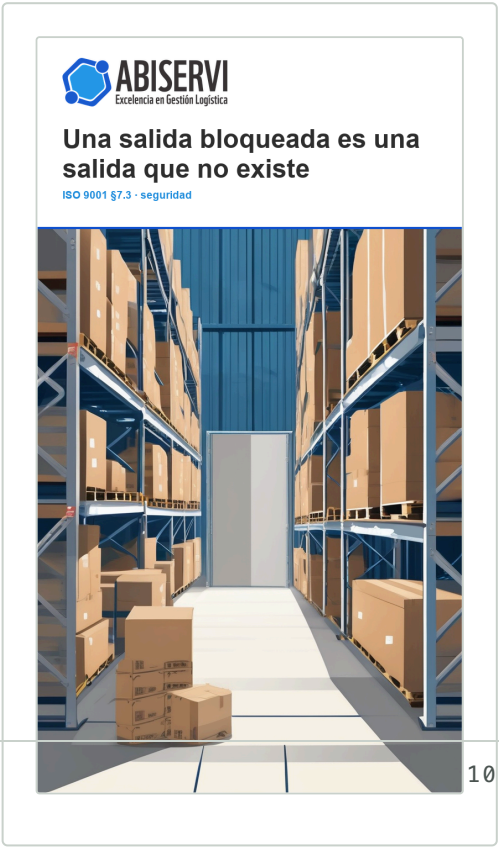
DIFUSIÓN CON SDXL

Difusión local para el material que exigen las cláusulas 7.2 a 7.4

ISO 9001 pide formar y comunicar en sus **cláusulas 7.2, 7.3 y 7.4**. El material de concienciación no es decoración: da servicio a tres cláusulas del estándar.



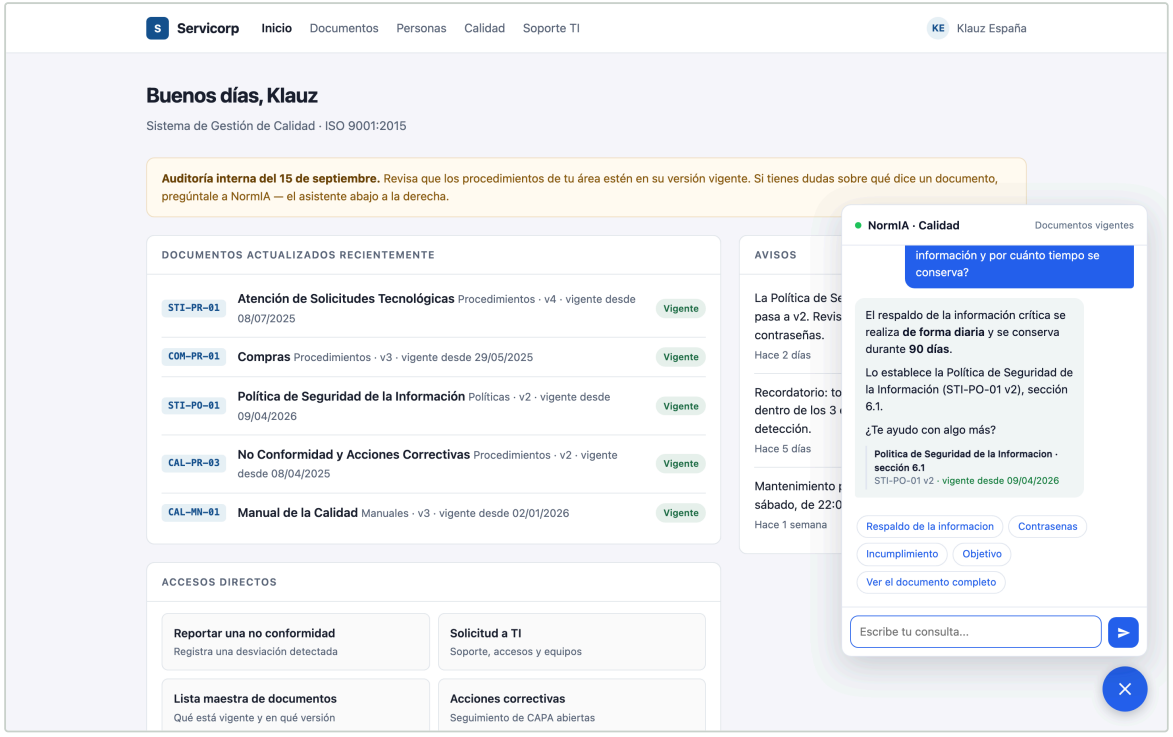




SDXL EN LOCAL, CON EL LOGOTIPO REAL

CAPTURAS REALES

El widget se integra en la intranet sin heredar ni imponer estilos



Respuesta fundamentada. El dato en negrita; debajo la referencia con el título por delante, y el código y la versión como respaldo.



QUÉ APORTA CADA PIEZA

La recuperación eleva el acierto del 8 % al 100 %

MÉTRICA	MODELO SOLO	CON RAG	RAG + FINE-TUNING
Acierta en conjunto	8 %	100 %	100 %
Cita el documento correcto	25 %	88 %	100 %
Sin citas inventadas	92 %	100 %	100 %
Latencia mediana	n/a	7,5 s	7,9 s

El modelo solo acierta 1 de 12. La recuperación lo lleva a 12 de 12, y el fine-tuning cierra la cita y acorta la respuesta.

Esa primera columna es la razón de ser del proyecto: un modelo sin los documentos delante responde con seguridad y **se inventa el código del procedimiento**.

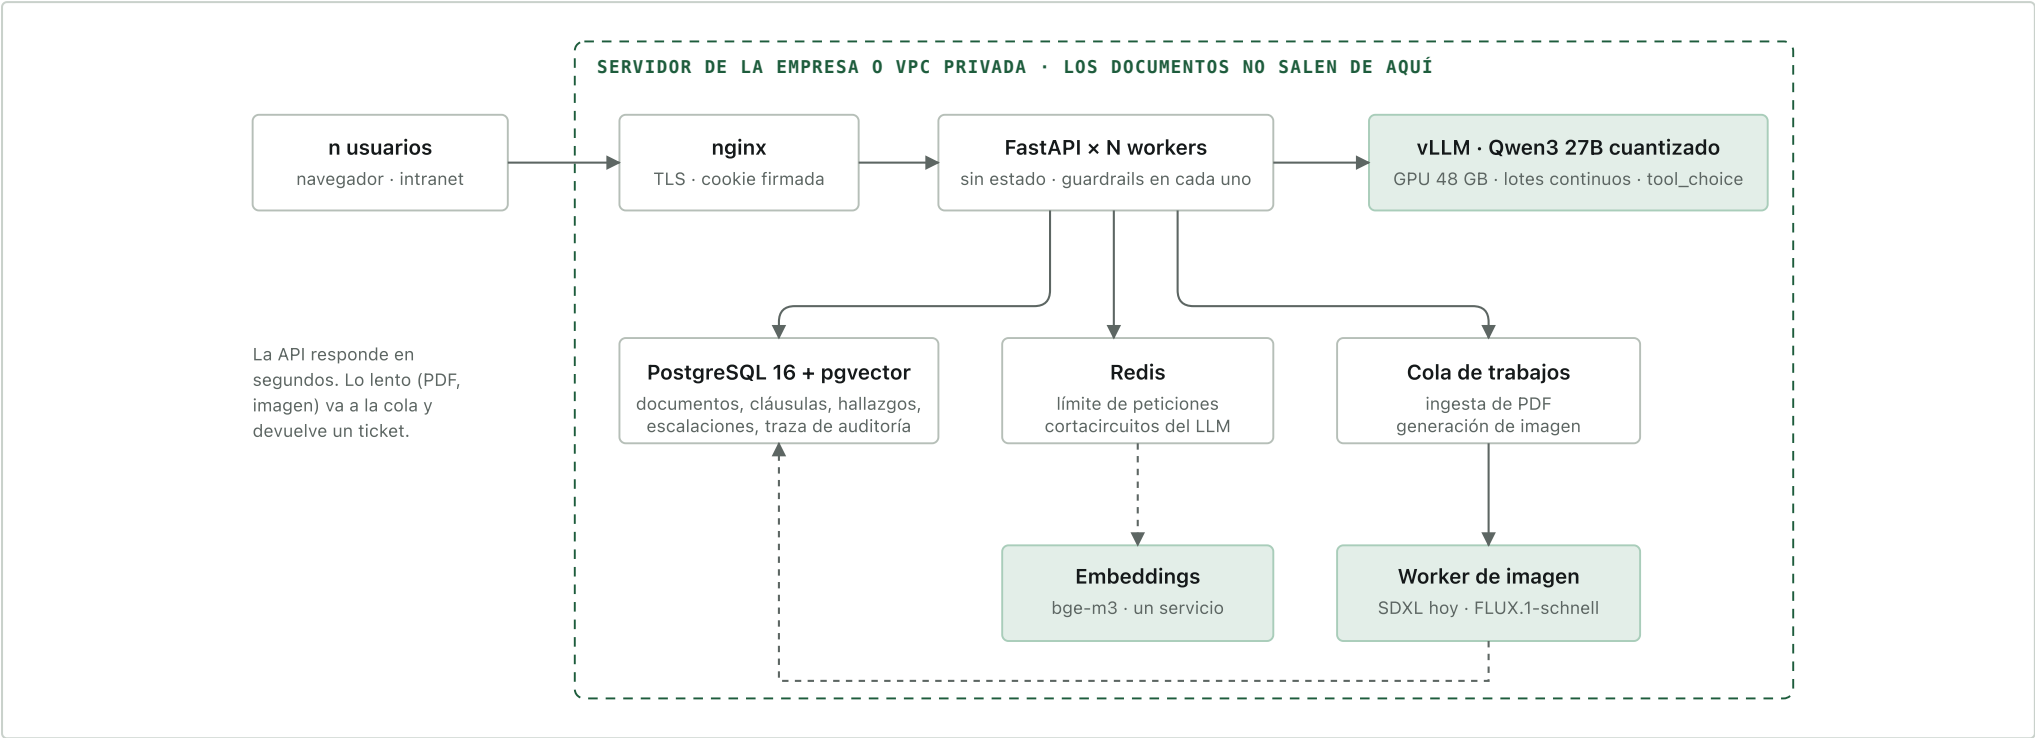
LO QUE NO SE DEMOSTRÓ

Seis limitaciones identificadas y medidas

- El banco son **12 consultas**. Suficiente para ver un patrón, corto para afirmar un porcentaje con intervalo de confianza.
- **Contenido inventado con cita real:** «tres cotizaciones para compras mayores a 1 000 soles», citando COM-PR-01 v3. El documento dice «una cotización». Se detecta (`citation_not_retrieved`) pero hoy no se bloquea.
- El fine-tuning **empeoró la emisión de llamadas** a herramienta, del 100 % al 75 %. Entrenar una llamada la empuja hacia su forma de texto.
- **24 cláusulas del SGC son imágenes** y una está escaneada: hoy se descartan en la ingesta. Harían falta OCR y un modelo de visión.
- El material visual **no entra en documentos controlados**. Formación sí; documento del SGC no: sería un problema de auditoría, no una mejora.
- Sin **pruebas de carga**: no se sabe cuántos usuarios concurrentes aguanta.

DEL PORTÁTIL AL SERVIDOR

El mismo código, servido a n usuarios desde un servidor



Lo que ya escala: PostgreSQL con pgvector, la sesión sin estado y el cliente del LLM con protocolo estándar. Lo que hay que sacar del proceso: límite de peticiones, cortacircuitos, ingesta e imagen. Una GPU de 48 GB con vLLM atiende del orden de 10–20 consultas simultáneas: **sin medir aún**, y por eso se dice así.

DE PROTOTIPO A PRODUCTO

Seis pasos para servir a n usuarios desde un servidor

PASO	POR QUÉ
Bloquear la cita no recuperada	El detector ya existe y registra el evento. Falta tratarlo como bloqueo, igual que la cita inexistente.
Servir con vLLM en vez de Ollama	**Medido:** Ollama ignora `tool_choice` y atiende en serie. Implica un servidor Linux con GPU: vLLM no corre en Mac.
Cola para lo lento	Generar una imagen bloquea un hilo 44 s. La ingesta de PDFs, igual.
Estado compartido en Redis	El cortacircuitos y el límite de peticiones viven en memoria del proceso: con dos instancias, cada una lleva su cuenta.
OCR y visión para lo escaneado	Recupera las 24 cláusulas que hoy se pierden.
LoRA de marca	18 piezas ya construidas. Daría identidad visual sin componer el logotipo.

Lo que **no** cambiaría: el modelo en local. Para un sistema de gestión certificado eso no es una ventaja técnica: es la condición para que el proyecto exista.